

```

1
2 from google.colab import drive
3 drive.mount('/content/drive')

Mounted at /content/drive

1 # Importar librerias:
2
3 import numpy as np
4 import matplotlib as plt
5 import pandas as pd
6 import csv
7 import seaborn as sns
8 import datetime
9 from datetime import timedelta
10
11 import matplotlib.pyplot as plt
12

1 path= '/content/drive/MyDrive/Ficheros de Vueling/2019RyanairCORT0.xlsx'
2 path= '/content/drive/MyDrive/Ficheros de Vueling/2019Ryanair.xlsx'

1 # Abrir fichero de Github.
2
3 Hoja = '2019Ryamair'
4 df = pd.read_excel(path, sheet_name=Hoja)
5

```

▼ Analitzo informació de la base de dades.

```

1 df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 750954 entries, 0 to 750953
Data columns (total 8 columns):
 #   Column                                                                 Non-Null Count  Dtype
---  -
 0   Mes, Día, Año de Flight_Date_Calculated_TST                        750954 non-null object
 1   scheduled_gate_departure                                           750946 non-null datetime64[ns]
 2   scheduled_gate_arrival                                             750951 non-null datetime64[ns]
 3   actual_gate_departure                                              721061 non-null datetime64[ns]
 4   actual_gate_arrival                                                726993 non-null datetime64[ns]
 5   tail_number                                                         746797 non-null object
 6   departure_airport_id                                               750954 non-null object
 7   arrival_at_cd_airport                                              746917 non-null object
dtypes: datetime64[ns](4), object(4)
memory usage: 45.8+ MB

1 # Els noms de les columnes tenen molts espais en blanc
2
3 nombreColumnas= df.columns
4 nombreColumnas

Index(['Mes, Día, Año de Flight_Date_Calculated_TST',
      'scheduled_gate_departure', 'scheduled_gate_arrival',
      'actual_gate_departure', 'actual_gate_arrival', 'tail_number',
      'departure_airport_id', 'arrival_at_cd_airport'],
      dtype='object')

```

```

1 # Aqui corrijo los nombre de las columnas
2 nombreColumnaCorregido= ['DATE', 'STD', 'STA', 'ATD','ATA', 'REG', 'DEP', 'ARR']
3
4
5 # Proceso para cambiar el nombre de las columnas por un bucle FOR
6 for n, m in enumerate(nombreColumnas):
7     print(n, m, '*', nombreColumnaCorregido[n], '-')
8     df.rename({m: nombreColumnaCorregido[n]}, axis=1, inplace=True)
9
10 df.head()

```

```

0 Mes, Día, Año de Flight_Date_Calculated_TST * DATE -
1 scheduled_gate_departure * STD -
2 scheduled_gate_arrival * STA -
3 actual_gate_departure * ATD -
4 actual_gate_arrival * ATA -
5 tail_number * REG -
6 departure_airport_id * DEP -
7 arrival_at_cd_airport * ARR -

```

	DATE	STD	STA	ATD	ATA	REG	DEP	ARR
0	1 de abril de 2019	2019-04-01 10:30:00	2019-04-01 12:50:00	2019-04-01 10:43:00	2019-04-01 12:55:00	EI-DAC	MXP	OTP
1	1 de abril de 2019	2019-04-01 13:20:00	2019-04-01 15:45:00	2019-04-01 13:40:00	2019-04-01 16:03:00	EI-DAC	OTP	MXP
2	1 de abril de 2019	2019-04-01 16:10:00	2019-04-01 18:00:00	2019-04-01 16:40:00	2019-04-01 18:20:00	EI-DAC	MXP	PMO
-	1 de abril de	2019-04-01	2019-04-01	2019-04-01	2019-04-01	EI-	----	-----

▼ Crear columnas de Mes, hora, etc

```

1 df['MES'] = df['STD'].dt.month
2 df['Setmana'] = df['STD'].dt.week
3 df['DiaSetmana'] = df['STD'].dt.dayofweek
4 df['DiaSetmanaName'] = df['STD'].dt.day_name()
5 df['Hour'] = df['STD'].dt.hour
6 df.head()

```

/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:2: FutureWarning: Series.dt.weekofyear and Seri

	DATE	STD	STA	ATD	ATA	REG	DEP	ARR	MES	Setmana	DiaSetmana	DiaSetmanaName	Hour
0	1 de abril de 2019	2019-04-01 10:30:00	2019-04-01 12:50:00	2019-04-01 10:43:00	2019-04-01 12:55:00	EI-DAC	MXP	OTP	4.0	14.0	0.0	Monday	10.0
1	1 de abril de 2019	2019-04-01 13:20:00	2019-04-01 15:45:00	2019-04-01 13:40:00	2019-04-01 16:03:00	EI-DAC	OTP	MXP	4.0	14.0	0.0	Monday	13.0

```

1 # Calculo tiempo de vuelo teorico Real y error
2
3 df['DuracionVueloTeorico1'] = (df['STA'] - df['STD']) / np.timedelta64(1, 'm')
4 df['DuracionVueloReal1'] = (df['ATA'] - df['ATD']) / np.timedelta64(1, 'm')
5 df['E_Duracion_Vuelo1'] = df['DuracionVueloReal1'] - df['DuracionVueloTeorico1']
6 df['E_Duracion_Vuelo1'].head(3)
7
8 media = round(df['E_Duracion_Vuelo1'].mean(), 2)

```

```

9
10 print('\n\nError medio en tiempo de vuelo',media)

Error medio en tiempo de vuelo -6.24
1 #Calculo error arribada:
2
3 df['E_Puntualidad1'] = (df['ATA']- df['STA']) / np.timedelta64(1, 'm')

1 #Calculo error enlairament:
2 df['E_Despegue1'] = (df['ATD']- df['STD']) / np.timedelta64(1, 'm')
3

```

▼ Calcul sequencia del vol per dia

```

1
2 df['Secuencia'] = df.groupby(['DATE', 'REG'])['STD'].rank().round(0)
3 print(df[['Secuencia','REG','STD', 'ARR']][0:6])

```

	Secuencia	REG	STD	ARR
0	1.0	EI-DAC 2019-04-01	10:30:00	OTP
1	2.0	EI-DAC 2019-04-01	13:20:00	MPX
2	3.0	EI-DAC 2019-04-01	16:10:00	PMO
3	4.0	EI-DAC 2019-04-01	18:45:00	MPX
4	1.0	EI-DAD 2019-04-01	05:30:00	BCN
5	2.0	EI-DAD 2019-04-01	07:55:00	OPO

```

1 value_counts = df['Secuencia'].value_counts()
2
3 Sequencies3 = pd.DataFrame(value_counts)
4 Sequencies3[:5]

```

	Secuencia
1.0	144225
2.0	142677
3.0	135663
4.0	131338
5.0	87773


```

1 # Agrupar per quantitat de vols,
2
3 value_counts = df['Secuencia'].value_counts()
4
5 Sequencies3 = pd.DataFrame(value_counts)
6
7 Sequencies3 = Sequencies3.reset_index()
8 Sequencies3.columns = ['Salt_nº', 'QuantitatVols'] # change column names
9 Sequencies3= Sequencies3[:9]
10
11 ax=sns.barplot(x = 'Salt_nº', y = 'QuantitatVols', data=Sequencies3)
12
13 ax.set_title('Quantitat de vols que te cada salt', fontsize = 24, color= 'green')
14 plt.suptitle(f'filtrat outliers')

```

```
Text(0.5, 1.0, 'Quantitat de vols que te cada salt')
```

Quantitat de vols que te cada salt



```
1 df1=df.copy()
2 df1.head()
```

	DATE	STD	STA	ATD	ATA	REG	DEP	ARR	MES	Setmana	DiaSetmana	DiaSetmanaName	Hour
0	1 de abril de 2019	2019-04-01 10:30:00	2019-04-01 12:50:00	2019-04-01 10:43:00	2019-04-01 12:55:00	EI-DAC	MXP	OTP	4.0	14.0	0.0	Monday	10.0
1	1 de abril de 2019	2019-04-01 13:20:00	2019-04-01 15:45:00	2019-04-01 13:40:00	2019-04-01 16:03:00	EI-DAC	OTP	MXP	4.0	14.0	0.0	Monday	13.0
	1 de ...	2019-	2019-	2019-	2019-	...							

▼ Creo el "lags" per tenir tots el registres en una sola linea

La idea de crear aquest lag es poder tenir en una sola linea tota la informació dels 3 salts que es que em pregunten. El que faig es pujar la celda a la linea de la Secuencia 1 de aquel avió y d'aquell dia. Despre's filtraré tot per la secuencia=1

```
1 #Creamos los LAGs
2 df[f'E_Despegue2'] = df['E_Despegue1'].shift(periods=-1)
3 df[f'E_Despegue3'] = df['E_Despegue1'].shift(periods=-2)
4
5 df[f'E_Duracion_Vuelo2'] = df['E_Duracion_Vuelo1'].shift(periods=-1)
6 df[f'E_Duracion_Vuelo3'] = df['E_Duracion_Vuelo1'].shift(periods=-2)
7
8 df[f'E_Puntualidad2'] = df['E_Puntualidad1'].shift(periods=-1)
9 df[f'E_Puntualidad3'] = df['E_Puntualidad1'].shift(periods=-2)
```

► Calcul temps a terra després del primer salt

```
[ ] ↳ 1 celda oculta
```

▼ Impacta de l'aeroport en el retard

```
1 # Agrupar per quantiat de vols,
2
3 value_counts = df1['ARR'].value_counts()
```

```

4
5 # converting to df and assigning new names to the columns
6 df_aeroports = pd.DataFrame(value_counts)
7
8 df_aeroports = df_aeroports.reset_index()
9 df_aeroports.columns = ['ARR', 'QuantitatVols'] # change column names
10
11
12
13 df_aeroports['Grup_Aeroport'] = df_aeroports["QuantitatVols"].apply(lambda x: int(x) if int
14
15 df_aeroports.Grup_Aeroport = df_aeroports.ARR.where(df_aeroports.QuantitatVols>19000, 'Resto')
16 df_aeroports=pd.DataFrame(df_aeroports)
17 df_aeroports
18

```

	ARR	QuantitatVols	Grup_Aeroport
0	STN	58731	STN
1	DUB	41018	DUB
2	BGY	29309	BGY
3	BCN	22893	BCN
4	MAD	19561	MAD
...
237	VIE	5	Resto
238	KEF	2	Resto
239	RVN	1	Resto
240	FDH	1	Resto
241	VCV	1	Resto

242 rows × 3 columns

```

1 # Incorporo la columna agrupada de Aeroports creada anteriormen
2
3 df1=pd.DataFrame(df1)
4 resultado= pd.merge(df1, df_aeroports)
5 resultado.drop(['QuantitatVols'], axis=1)
6

```

	DATE	STD	STA	ATD	ATA	REG	DEP	ARR	MES	Setmana	DiaSetmana	DiaSetmana
0	1 de abril de 2019	2019-04-01 10:30:00	2019-04-01 12:50:00	2019-04-01 10:43:00	2019-04-01 12:55:00	EI-DAC	MXP	OTP	4.0	14.0	0.0	Mc
1	1 de abril de 2019	2019-04-01 16:20:00	2019-04-01 18:25:00	2019-04-01 16:20:00	2019-04-01 18:06:00	EI-DWD	CIA	OTP	4.0	14.0	0.0	Mc
2	1 de abril de 2019	2019-04-01 16:15:00	2019-04-01 18:25:00	2019-04-01 17:16:00	2019-04-01 19:22:00	EI-DWR	SXF	OTP	4.0	14.0	0.0	Mc
3	1 de abril de 2019	2019-04-01	2019-04-01	2019-04-01	2019-04-01	EI-DWT	SXF	OTP	4.0	14.0	0.0	Mc

```

1 # Filtro els outliers
2
3 df3=resultado.copy()
4 dfEliminarOutliers= ((resultado['Secuencia']== 1) & (resultado['E_Despegue1']< 30) & (resul
5
6 df3 = df3[dfEliminarOutliers]

```

7	40912	NOVIEMBRE	11-14	INDI	INDI	INDI	INDI	VCV	REF	11.0	40.0	5.0	INDI
---	-------	-----------	-------	------	------	------	------	-----	-----	------	------	-----	------

```

1 value_counts = df3['Grup_Aeroport'].value_counts()
2
3 df_aeroports2 = pd.DataFrame(value_counts)
4 df_aeroports2

```


	Grup_Aeroport	
Resto	110187	
STN	8301	
BGY	4521	
MAD	3416	
DUB	3098	
BCN	3023	

```

1 # Intervals de confiança per aeroport
2
3 sns.set_theme(style="darkgrid")
4 #tips = sns.dfl("tips")
5 sns.set(rc = {'figure.figsize':(15,8)})
6 # Tamaño de la imagen
7 ax = sns.pointplot(x='Grup_Aeroport', y = "E_Despegue1", data= df3, scale=.1, kind = "point
8
9 puntualidadBCN = round((df3['E_Despegue1'].mean()),2)#
10
11 ax.axhline(puntualidadBCN, color="red", linestyle = '--', label="oas") # Linea 0 ver
12 ax.axhline(0, color="green", linestyle = '--')
13
14
15 textoBCN = "BCN puntualitat mitja"+ str(puntualidadBCN) + ' minut.'
16 ax.text(puntualidadBCN +50 ,puntualidadBCN , textoBCN, backgroundcolor='w')
17
18 ax.set_title('Puntualitat 1er enlairament principals Aeroports:', fontsize = 24, color= 'gr
19 plt.suptitle(f'filtrat outliers')

```

Text(0.5, 0.98, 'filtrat outliers')



▸ df2 Seqüència 1 - Barcelona

```
1 # Filtre primer enlairament a Barcelona
2
3 vuelosPrimerDespegue= ((df1['Secuencia']== 1) & (df1['DEP']=='BCN'))
4 df2 = df1[vuelosPrimerDespegue]
5 print(df2[['DATE', 'REG', 'Secuencia', 'STD']][0:8])
```

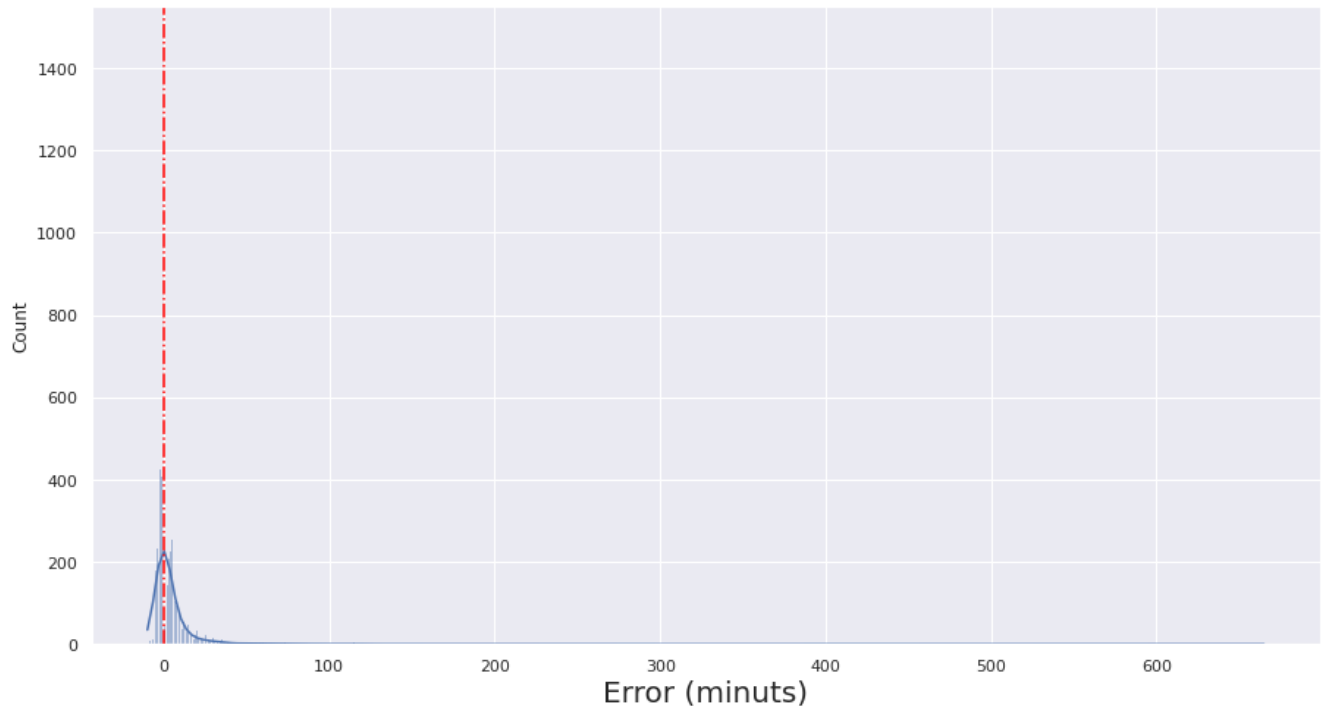
	DATE	REG	Secuencia	STD
193	1 de abril de 2019	EI-DHF	1.0 2019-04-01 04:05:00	
214	1 de abril de 2019	EI-DHR	1.0 2019-04-01 04:00:00	
294	1 de abril de 2019	EI-DLJ	1.0 2019-04-01 04:15:00	
528	1 de abril de 2019	EI-DWM	1.0 2019-04-01 04:20:00	
774	1 de abril de 2019	EI-EBW	1.0 2019-04-01 06:40:00	
947	1 de abril de 2019	EI-EKN	1.0 2019-04-01 06:30:00	
1554	1 de abril de 2019	EI-FOK	1.0 2019-04-01 04:30:00	
1566	1 de abril de 2019	EI-FOM	1.0 2019-04-01 05:50:00	

▸ Impacta dels outliers.

Mostrar código

Text(0.5, 0, 'Error (minuts)')

Distribució Error 1r enlairament




Aquí veiem que els **outliers** afectaran moltíssim al resultat final, per això sempre els hem de filtrar les dades

▸ Eliminar los outliers

[Mostrar código](#)

```
Mitjana filtrada = 2.05 minuts
Text(0.5, 0, 'Error (minuts)')
```

Error d'enlairament 1r salt, filtrat a BCN




Enlairament Barcelona La sortida de Barcelona, la seva moda clarament es veu que és 0, però la seva mitjana es de 2.05 minuts tard

► Intervalos de Confianza durant el dia

[Mostrar código](#)

```
Text(0.5, 1.0, 'Puntualitat enlairament per hora del dia:')
```




▼ Estudi puntualitat primer salt


```

1 plt.figure(figsize = (15,8))
2 p= sns.histplot(data= df.E_Puntualidad1, kde= True)
3 p.axvline(x = 0, ymin=0, ymax= 12, color='red', linestyle= 'dashdot') # Objetivo
4 p.set_title('Distribució Error Puntualitat', fontsize=25, color='green')
5 p.set_xlabel("Error (minuts)", fontsize = 20)

Text(0.5, 0, 'Error (minuts)')

```




Aquí clarament es veu que hi ha molts d'outliers. Acordem per convenció que limitarem les anàlisis a només els vols que tenen entre -30 y +30 minuts de falta de puntualitat.

```

1 # Eliminar els outliers
2 df2=df.copy()
3 dfEliminarOutliers= ( (df2['E_Puntualidad1']< 30) & (df2['E_Puntualidad1']> -30))
4
5 df2 = df2[dfEliminarOutliers]
6 #
7 plt.figure(figsize = (15,8))
8 p= sns.histplot(data= df2.E_Puntualidad1, kde= True)
9 p.set_title("Error de puntualitat filtrat", fontsize=25, color='green')
10
11 mediaFiltrada = round(df2['E_Puntualidad1'].mean(),2)
12 p.axvline(mediaFiltrada, 0,12, color = 'green') # Media real
13 p.axvline(x = 0, ymin=0, ymax= 12, color='red', linestyle= 'dashdot') # Objetivo
14 print()
15 print('Mitjana filtrada = ', mediaFiltrada, 'minuts')
16 #print(df2[['Secuencia', 'E_Despegue', 'AeropuertoKey1' ]])
17 p.set_xlabel("Error (minuts)", fontsize = 20)

```

```
Mitjana filtrada = -1.47 minuts
Text(0.5, 0, 'Error (minuts)')
```



Conclusió:

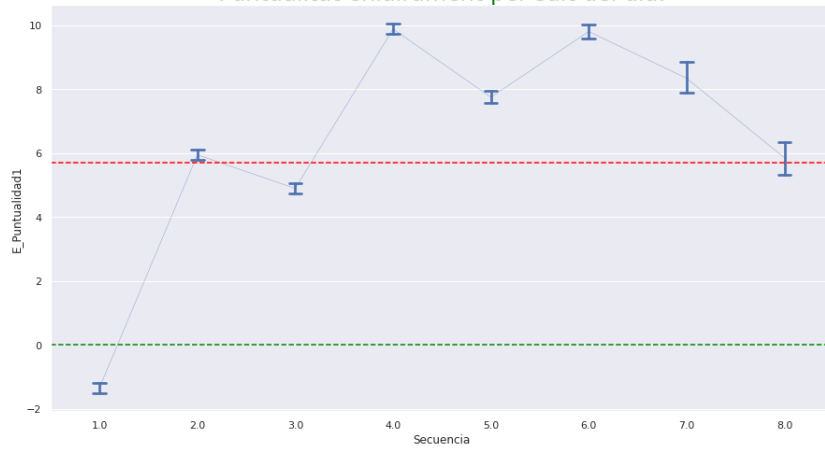
En el primer salt veiem que la mitjana es de -1.47 minuts d'avançament a l'hora de la sortida.

▼ Intervals de Confianza per salt

```
1 #@title Intervals de Confianza per salt
2
3 # Trec tots els registres que no tinc el "REG" de l'avió.
4
5 filtered_df = df[df['REG'].notnull()]
6
7 # Limito el gràfic només als primers 9 salts per dia
8 dfEliminarMesGrans9Salts = ( ( filtered_df['Secuencia']< 9))
9 filtered_df = filtered_df[dfEliminarMesGrans9Salts]
10
11
12 sns.set_theme(style="darkgrid")
13 #tips = sns.df1("tips")
14 sns.set(rc = {'figure.figsize':(15,8)})
15 # Tamaño de la imagen
16 ax = sns.pointplot(x='Secuencia', y = "E_Puntualidad1", data= filtered_df, scale=.1, kind =
17
18 puntualidadBCN = round((df['E_Puntualidad1'].mean()),2)#
19
20 ax.axhline(puntualidadBCN, color="red", linestyle = '--', label="oas")          # Línea 0 ver
21 ax.axhline(0, color="green", linestyle = '--')
22
23
24 textoBCN = "BCN puntualitat mitja"+ str(puntualidadBCN) + ' minut.'
25 ax.text(puntualidadBCN+5 ,puntualidadBCN , textoBCN, backgroundColor='w')
26
27 ax.set_title('Puntualitat enlairament per salt del dia:', fontsize = 24, color= 'green')
28
29
```

Text(0.5, 1.0, 'Puntualitat enlairament per salt del dia:')

Puntualitat enlairament per salt del dia:



BCN puntualitat mitja 5.7 minut.

A lo llarg del dia


```

1 f, axes = plt.subplots(1, 2, figsize=(16, 9))
2
3 ax1=sns.boxplot( x='Secuencia', y = "E_Puntualidad1", data= filtered_df, orient='v' , ax=
4 #axes.set_title("Title for first plot")
5 ax1.axhline(10, color="green", linestyle = '--' )
6
7 ax2=sns.boxplot( x='Secuencia', y = "E_Puntualidad1", data= filtered_df, orient='v' , ax=
8 ax2.axhline(10, color="green", linestyle = '--' )
9 ax2.axhline(0, color="red", linestyle = '--' )
10 ax1.set_title('Puntualitat per salt del dia, veien outliers:', fontsize = 13, color= 'greer
11 ax2.set_title('Puntualitat per salt del dia,', fontsize = 15, color= 'blue')

```

```
Text(0.5, 1.0, 'Puntualitat per salt del dia,')
```

Puntualitat per salt del dia, veien outliers:



Puntualitat per salt del dia,



```
1 prueba= filtered_df
2
3 dfEliminarOutliers= ( (filtered_df['Secuencia']> 8))
4
5 prueba = prueba[dfEliminarOutliers]
6 prueba
```

DATE	STD	STA	ATD	ATA	REG	DEP	ARR	MES	Setmana	...	E_Despegue2	E_Despegue3	E_Duracion_Vuelo2	E_
0 rows × 29 columns														

```
1 # Prova per verificar que és veritat que hi ha més de 6 salts per dia d'un avió
2 prueba= filtered_df
3
4 dfEliminarOutliers= ( ( filtered_df['REG']=='EI-FTA') & (filtered_df['DATE']=='9 de agosto
5 prueba2 = prueba[dfEliminarOutliers]
6 prueba2.tail(3)
```

	DATE	STD	STA	ATD	ATA	REG	DEP	ARR	MES	Setmana	...	E_Despegue2	E_Despe
730435	9 de agosto de 2019	2019-08-09 14:00:00	2019-08-09 15:10:00	2019-08-09 14:52:00	2019-08-09 15:55:00	EI-FTA	BHX	DUB	8.0	32.0	...	54.0	
730436	9 de agosto de 2019	2019-08-09 15:40:00	2019-08-09 16:45:00	2019-08-09 16:34:00	2019-08-09 17:45:00	EI-FTA	DUB	MAN	8.0	32.0	...	67.0	
730437	9 de agosto ,	2019-08-09	2019-08-09	2019-08-09	2019-08-09	EI-FTA	MAN	DUB	8.0	32.0	...	68.0	

```
1 # Prova per verificar que és veritat que hi ha Números de seqüència que no són enters.
2
3 prueba= filtered_df
4
5 dfEliminarOutliers= ( ( filtered_df['REG']=='EI-ENM') & (filtered_df['DATE']=='1 de juli
6 prueba2 = prueba[dfEliminarOutliers]
7 prueba2
```

	DATE	STD	STA	ATD	ATA	REG	DEP	ARR	MES	Setmana	...	E_Despegue2	E_Despegue1
11110	1 de julio de 2019	2019-07-01 05:00:00	2019-07-01 09:05:00	2019-07-01 05:47:00	2019-07-01 09:53:00	EI-ENM	BRU	LCA	7.0	27.0	...	124.0	12

	DATE	STD	STA	ATD	ATA	REG	DEP	ARR	MES	Setmana	DiaSetmana	DiaSetmanaName	Hour	DuracionVueloTeorico1	DuracionVueloReal1	E_Duracion_Vuelo1	E_Puntualidad1	E_Despegue1	Secuencia
11110	1 de julio de 2019	2019-07-01 05:00:00	2019-07-01 09:05:00	2019-07-01 05:47:00	2019-07-01 09:53:00	EI-ENM	BRU	LCA	7.0	27.0	0.0	Monday	5.0	245.0	246.0	1.0	48.0	47.0	1.0
11111	1 de julio de 2019	2019-07-01 09:30:00	2019-07-01 14:00:00	2019-07-01 11:34:00	2019-07-01 15:54:00	EI-ENM	LCA	BRU	7.0	27.0	0.0	Monday	9.0	270.0	260.0	-10.0	114.0	124.0	2.0
11112	1 de julio de 2019	2019-07-01 16:30:00	2019-07-01 18:15:00	2019-07-01 16:42:00	2019-07-01 18:23:00	EI-ENM	BRU	DUB	7.0	27.0	0.0	Monday	16.0	105.0	101.0	-4.0	8.0	12.0	3.0
11113	1 de julio de 2019	2019-07-01 18:40:00	2019-07-01 19:45:00	2019-07-01 18:55:00	2019-07-01 20:00:00	EI-ENM	DUB	EMA	7.0	27.0	0.0	Monday	18.0	65.0	65.0	0.0	15.0	15.0	4.0
11114	1 de julio de 2019	2019-07-01 18:40:00	2019-07-01 20:25:00	2019-07-01 21:59:00	2019-07-01 23:25:00	EI-ENM	DUB	BRU	7.0	27.0	0.0	Monday	18.0	105.0	86.0	-19.0	180.0	199.0	4.0
11115	1 de julio de 2019	2019-07-01 20:25:00	2019-07-01 21:30:00	2019-07-01 20:29:00	2019-07-01 21:23:00	EI-ENM	EMA	DUB	7.0	27.0	0.0	Monday	20.0	65.0	54.0	-11.0	-7.0	4.0	6.0

2019 10.30.00 10.15.00 10.42.00 10.23.00

Alerta: el vol que ha arribat a Dublín s'ha dividit en 2 capa EMA i capa BRU

11113	JULIO	07-01	07-01	07-01	07-01	EI-	DUB	EMA	7.0	27.0		100.0	4
-------	-------	-------	-------	-------	-------	-----	-----	-----	-----	------	--	-------	---

▼ Impacta del "MES" en la puntualitat


▼ Intervalos de confianza per mes

```

1 #@title Intervalos de confianza per mes
2
3 sns.set_theme(style="darkgrid")
4 #tips = sns.df1("tips")
5 sns.set(rc = {'figure.figsize':(15,8)})
6 # Tamaño de la imagen
7 ax = sns.pointplot(x='MES', y = "E_Puntualidad1", data= df3, scale=.1, kind = "point", cap:
8
9 puntualidadBCN = round((df3['E_Puntualidad1'].mean()),2)#
10 print('Puntualitat BCN 1r salt: ', puntualidadBCN)
11 ax.axhline(puntualidadBCN, color="red", linestyle = '--', label="oas") # Linea 0 ver
12 ax.axhline(0, color="green", linestyle = '--')
13
14
15 textoBCN = "BCN puntualitat mitja"+ str(puntualidadBCN) + ' minut.'
16 ax.text(puntualidadBCN +50 ,puntualidadBCN , textoBCN, backgroundcolor='w')
17
18 ax.set_title('Puntualitat 1er salt per mesos del 2019 a BCN:', fontsize = 24, color= 'greener')
19 plt.suptitle(f'filtrat outliers')

```

Puntualitat BCN 1r salt: -5.27
Text(0.5, 0.98, 'filtrat outliers')



BCN puntualitat mitja -5.27 minut.

▼ Quantitat vols en el primer salt.

▼ df4 Group --> MES, ve de df3.

```
1 #@title df4 Group --> MES, ve de df3.
2
3 df4= df3.copy() #[df3['MES', 'Secuencia']]
4 df4=df4.groupby(['MES', 'Secuencia']).size()
5 df4 = df4.reset_index()
6 #df4['Quantitat']=df3.groupby(['MES', 'Secuencia']).size()
7 df4.columns = ['MES','Secuencia','QuantitatVols']
8 df4
```


	MES	Secuencia	QuantitatVols
0	1.0	1.0	10493
1	2.0	1.0	9549
2	3.0	1.0	10651
3	4.0	1.0	11711
4	5.0	1.0	12320
5	6.0	1.0	12120
6	7.0	1.0	11415
7	8.0	1.0	12122
8	9.0	1.0	11595
9	10.0	1.0	11737
10	11.0	1.0	9688
11	12.0	1.0	9145

```
1 #df4.columns = ['MES', 'QuantitatVols'] # change column names
2 ax=sns.barplot(x = 'MES', y = 'QuantitatVols', data=df4)
3
4 ax.set_title('Quantitat de vols de 1er salt per mes', fontsize = 24, color= 'green')
5 quantitatVolsMitjana= df4.QuantitatVols.mean()
6 ax.axhline(quantitatVolsMitjana,color="red", linestyle = '--', label="oas") # Linea
7 ax.axhline(0, color="green", linestyle = '--')
8 plt.suptitle(f'filtrat outliers')
```

```
Text(0.5, 0.98, 'filtrat outliers')
```

filtrat outliers

Quantitat de vols de 1er salt per mes



Veiem que a l'estiu hi han mes vols. Això vol dir que la probabilitat de ahver mes traffic influeis en la puntualitat



▼ crec el df5

```
1 #@title crec el df5
2 df5=df[['DEP', 'MES', 'E_Puntualidad1', 'Secuencia']].copy()
3
4 df5.media = df5.groupby(['MES']).mean('E_Puntualidad1')
5
6 df5.media
7 #df5
```

/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:4: UserWarning: Pandas doesn't allow columns to be removed from sys.path.

	E_Puntualidad1	Secuencia
MES		
1.0	5.080506	5.835441
2.0	1.407520	7.254976
3.0	0.172117	7.596379
4.0	5.851469	11.910303
5.0	6.044040	16.580894
6.0	9.439683	10.658061
7.0	9.647667	13.584548
8.0	7.102275	11.382026
9.0	8.154873	13.550766
10.0	3.664877	25.187482
11.0	1.179958	15.185388
12.0	7.190552	42.514854

```
1 # Filtre primer enlairament a Barcelona
2
3 vuelosPrimerDespegue= ((df5['Secuencia']== 1) & (df5['DEP']=='BCN'))
4 df5 = df5[vuelosPrimerDespegue]
5 df5.media = df5.groupby(['MES']).mean('E_Puntualidad1')
6
7 print("Puntualitat a l'arribada a BCN en el primer salt")
8 df5.media['E_Puntualidad1']
```

Puntualitat a l'arribada a BCN en el primer salt

/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:5: UserWarning: Pandas doesn't allow columns to be removed from sys.path.

MES

```

1.0    -2.251232
2.0    -0.814249
3.0    -3.339367
4.0    -1.821687
5.0    -0.393258
6.0    -2.243119
7.0    -2.476309
8.0    -3.832952
9.0     1.360190
10.0   -1.514739
11.0   -1.670792
12.0    3.807143
Name: E_Puntualidad1, dtype: float64

```

▼ Calcular els valors de Cp i Cpk

▼ Subrutina para el calcul del Cp i el Cpk

```

1 #@title Subrutina para el calcul del Cp i el Cpk
2
3 def Cp(clave, usl, lsl):
4
5     sigma = df3[clave].std()
6
7     Cp = abs(round((usl - lsl) / (6*sigma),2))
8     print('Valor del Cp= ', Cp)
9     return Cp
10
11 def Cpk(clave, usl, lsl):
12
13     sigma = df3[clave].std()
14     m = round(np.mean(df2[clave]),2)
15     print('mitjana ', m)
16
17     Cpu = float(-usl + m) / (3*sigma)
18     Cpl = float(-m + lsl) / (3*sigma)
19     #print('Cpks ', Cpu, Cpl)
20     Cpk = round( np.min([Cpu, Cpl]),2)
21     print('Valor del Cpk= ', Cpk)
22
23     return Cpk

```



```

1
2 Cp('E_Puntualidad1', -30, 30)
3 Cpk('E_Puntualidad1', -30, 30)
4 print('\nSegond salt')
5 #Cp('E_Puntualidad2', -30, 30)
6 #Cpk('E_Puntualidad2', -30, 30)

```



```

Valor del Cp=  0.78
mitjana  -1.47
Valor del Cpk=  0.75

```



```

Segond salt

```

Comentari als valors de Cp i Cpk Veiem que els valors de Cp i Cpk són molt baixos perquè en el món de l'Automòbil els valors acceptats són 1,33 que vol dir que som capaços de ficar 1,3 la corba de Gauss dintre dels límits (-30 i 30 minuts).

▼ Conclusion generals per salt:

▼ gràfic generals per salt (tots els aeroport):

```

1 #@title gràfic generals per salt (tots els aeroport):
2
3 campo = ['E_Despegue1', 'E_Despegue2', 'E_Despegue3', 'E_Duracion_Vuelo1', 'E_Duracion_Vuelo2']
4 df_Errors = df.loc[:, campo]
5 for t in campo:
6
7     dfEliminarOutliers = ((df_Errors[t] > -30) & (df_Errors[t] < 30))
8
9     df_Errors = df_Errors[dfEliminarOutliers]
10 fig = plt.figure()
11 for i, column in enumerate(df_Errors.columns, 1):
12     plt.subplot(3, 3, i)
13     sns.histplot(df_Errors[column], kde=True) #, stat='density')
14
15     plt.plot([0, 0], [1500, 30000], color='red', linestyle='dashdot')
16     media = round(df_Errors[column].mean(), 2)
17     plt.plot([media, media], [1500, 30000], color='green')
18     #plt.set_title
19     #print(max(df_Errors[column]), media)
20     plt.text(0.5, 10000, column,
21             horizontalalignment='center',
22             fontsize=15,
23             )
24     texto = 'mitjana: ' + str(media) + ' minuts'
25     plt.text(10, 20000, texto,
26             horizontalalignment='center',
27             fontsize=10,
28             color='blue'
29             )
30 fig.suptitle("Puntualitat per salt (tots els aeroport)")

```

```
Text(0.5, 0.98, 'Puntualitat per salt (tots els aeroport)')
```

Puntualitat per salt (tots els aeroport)

80000

El gràfic demostra que:

1.- A l'hora de enlairar-se el comportament és sortir tard uns 3 minuts.

2.- En vol recuperar uns 6 minuts.

3.- I la puntualitat és (3 -6) = 3 minuts abans

Nota: Cada columna es un salt.

8

E_Duracio_Vuelo1

8

E_Duracio_Vuelo2

8

E_Duracio_Vuelo3

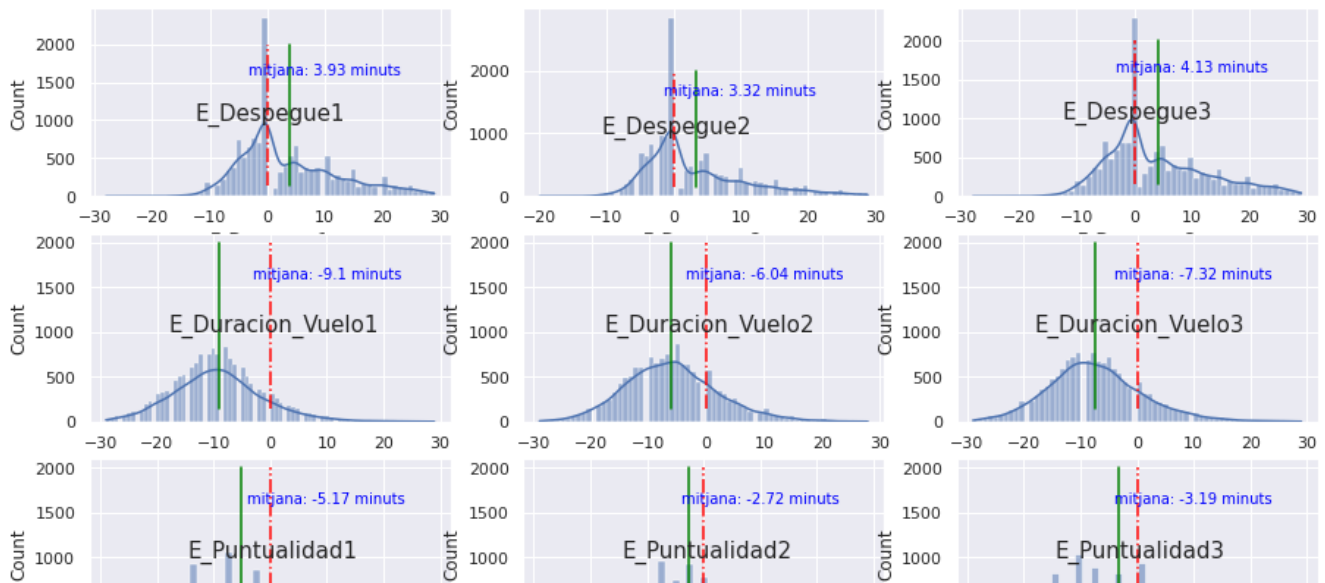
▼ graficar la operativitat de BCN

```
1 #@title graficar la operativitat de BCN
2 # Eliminar els outliers
3 df6=df.copy()
4 dfEliminarOutliers= ( (df['E_Puntualidad1']< 30) & (df['E_Puntualidad1']> -30) & (df['ARR']
5
6 df6 = df[dfEliminarOutliers]
7
8 campo = ['E_Despegue1','E_Despegue2','E_Despegue3','E_Duracion_Vuelo1', 'E_Duracion_Vuelo2'
9
10 df_Errores1= df6.loc[:,campo]
11 for t in campo:
12     dfEliminarOutliers= ((df_Errores1[t]>-30) & (df_Errores1[t]<30) & (df['ARR']=='BCN'))
13     df_Errores1 = df_Errores1[dfEliminarOutliers]
14
15 fig=plt.figure()
16 for i, column in enumerate(df_Errores1.columns, 1):
17     plt.subplot(3,3,i)
18     sns.histplot(df_Errores1 [column], kde=True)#, stat='density')
19
20     plt.plot([0, 0], [150, 2000], color='red', linestyle= 'dashdot')
21     media= round(df_Errores1[column].mean(),2)
22     plt.plot( [media,media], [150, 2000], color='green')
23     #plt.set_title
24     #print(max(df_Errores [column]), media)
25     plt.text(0.5, 1000, column,
26             horizontalalignment='center',
27             fontsize=15,
28             )
29     texto = 'mitjana: '+ str(media) + ' minuts'
30     plt.text(10, 1600, texto,
31             horizontalalignment='center',
32             fontsize=10,
33             color='blue'
34             )
35
36 fig.suptitle("Puntualitat a l'aeroport de BCN")
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:13: UserWarning: Boolean Series key will be reindexed in place by the boolean mask in the next call to df.__getitem__
del sys.path[0]
```

```
Text(0.5, 0.98, "Puntualitat a l'aeroport de BCN")
```

Puntualitat a l'aeroport de BCN



▼ Salvar el fitxer princial.

```
1 guardar = 'No'
2 # Guardar excel
3 if guardar != 'No':
4     nombreFichero = "D:\Documentos D\02.- Datos Vueling\Ryainair2019_" + Hoja + '_' + str(fecha)
5
6     df3.to_excel(nombreFichero)
7     print()
8     print('Guardado fichero : ', nombreFichero)
9     print()
10 else:
11     print('No guardado')
```

No guardado

✓ 0 s completado a las 8:23

